Cloud Barista

멀티/분산 클라우드, 차세대 클라우드를 향한 도전과 기회

- 클라우드바리스타 커뮤니티 제9차 컨퍼런스 -

AI 서비스 인프라를 위한 CB-Tumblebug의 여정

멀티 클라우드 인프라 통합 관리 기술

메인테이너@Cloud-Barista

손 석 호

시나몬 (Cinnamon) 한잔 어떠세요 ?

목 차

CB-Tumblebug 개요

- 최적의 멀티 클라우드 인프라를 통합 배포, 제어, 관리하는 서비스 및 시스템

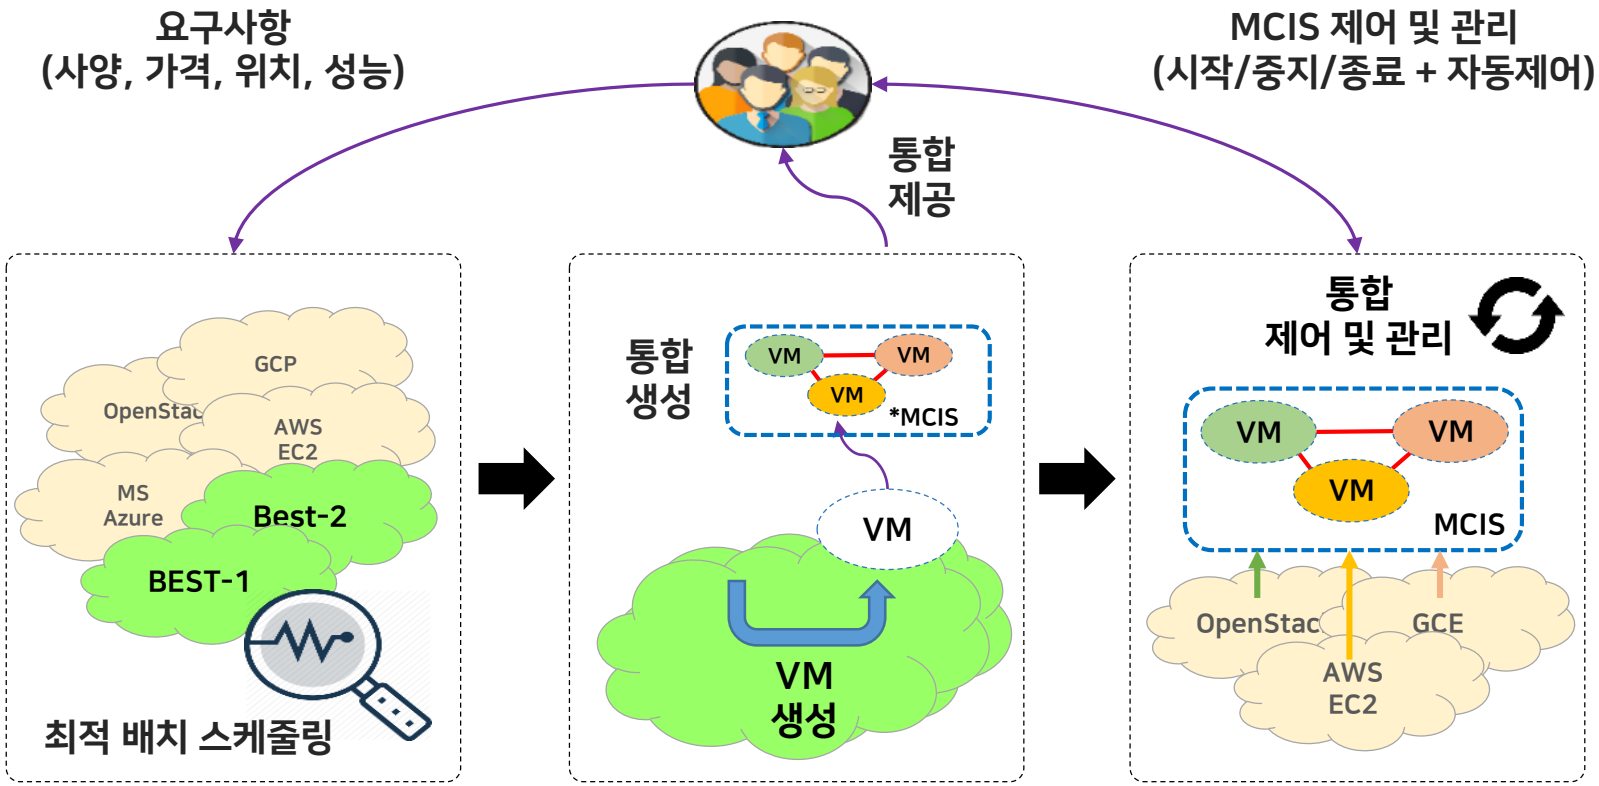

*MCIS: 멀티클라우드 인프라 서비스

성능 벤치마킹 기반 최적 멀티 클라우드 인프라

최적 클라우드 인프라 제공을 통한 효율성 증대

멀티 클라우드 인프라 통합 운용 자동화

통합 제어, 정책 적용 등 관리 편의성 극대화

CB-Tumblebug 특징

Cloud-Barista 멀티 클라우드 인프라 형상 – 1/2

- 멀티 클라우드 인프라 서비스 (MCIS: Multi-Cloud Infra Service)
  - 지역적으로 격리된 다수의 클라우드 환경에서
    단일 목적(응용서비스, 애플리케이션 등)을 위해
    하나 이상의 클라우드 인프라(가상머신 등)를
    조합 및 상호 연계한 컴퓨팅 인프라 그룹
  - 용도 : 멀티 클라우드 인프라의 통합 제어 및 관리

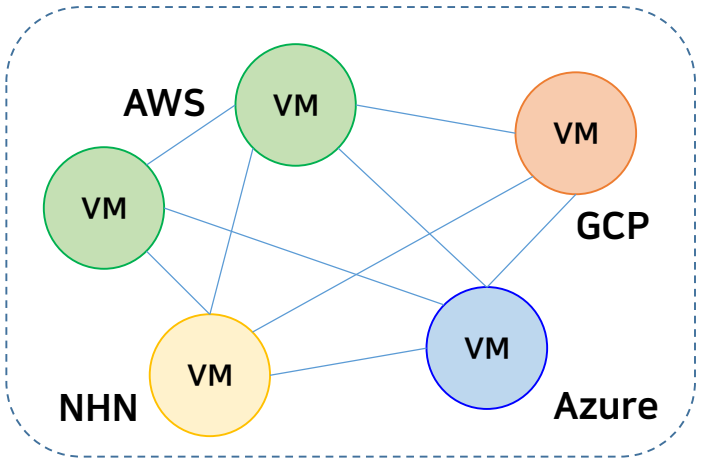

[MCIS 예시]

- 멀티 클라우드 인프라 리소스 (MCIR: Multi-Cloud Infra Resource)
  - 다수의 클라우드 환경에서 컴퓨팅 인프라 생성을 위해 관리
    하는 모든 리소스 (예: vNet, Image, Security Group, …)
  - 용도 : MCIS 구성 및 설정을 위한 리소스

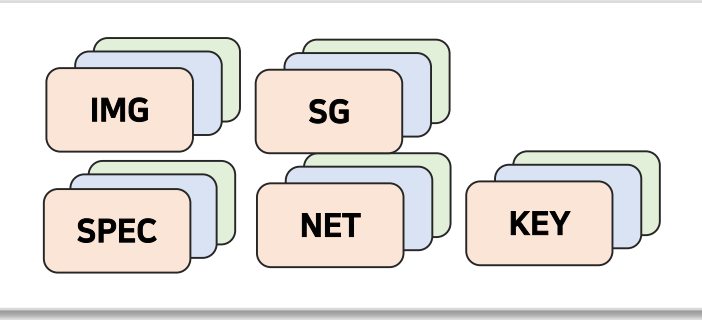

[MCIR 예시]

Cloud-Barista 멀티 클라우드 인프라 형상 – 2/2

MCIS(Multi-Cloud Infra Service) 형상

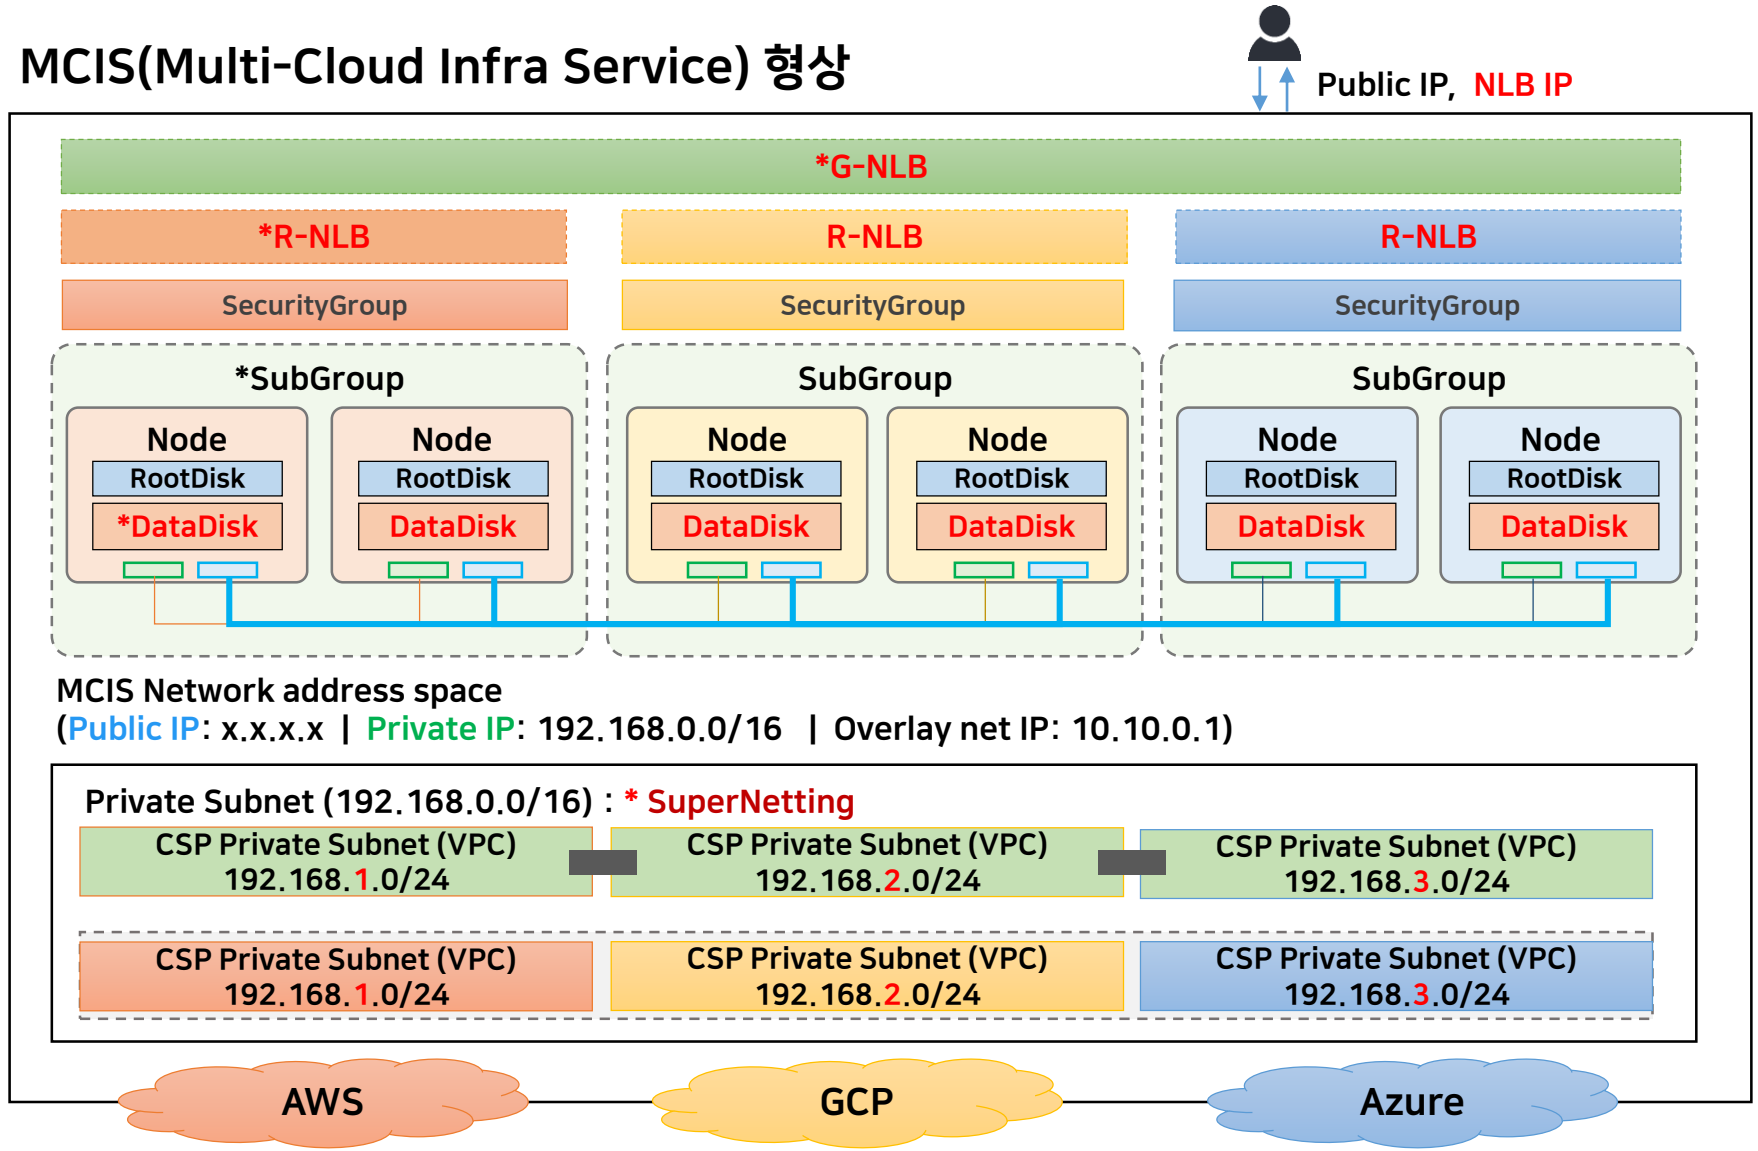

*** NLB**
네트워크 로드벨런서(L4)
- G-NLB: Global (SW 기반)
- R-NLB: Regional (CSP 서비스)

*** SubGroup(Node Group)**
동일 속성을 가진 Node 및 리소스그룹 (VM)

*** DataDisk**
Volume을 생성, 관리, 할당

*** Site-to-Site VPN**
CSP VPN 서비스를 통한 보안 터널링

*** SuperNetting**
더 많은 IP 주소 공간 활용, 라우팅 테이블 단순화, 터널링 등에 활용

(참고) CB-Tumblebug 기능 및 API

README | Code of conduct | Apache-2.0 license

CB-Tumblebug (Multi-Cloud Infra Service Management)

go report A+ | build passing | go 71.7% | go.mod v1.21.6 | repo size 34 MB | reference | API Doc Swagger

release v0.8.0 | release(dev) v0.8.11 | license Apache-2.0 | Slack SIG-TB

all contributors 41

A sub-system of Cloud-Barista Platform to Deploy and Manage Multi-Cloud Infrastructure.

- CB-Tumblebug Overview (Korean)
- CB-Tumblebug Features (Korean)
- CB-Tumblebug Architecture (Korean)
- CB-Tumblebug Operation Sequence

▶ [Note] CB-Tumblebug is currently under development

▶ [Note] Localization and Globalization of CB-Tumblebug

[한국어, English]

목차

1. CB-Tumblebug 실행 및 개발 환경
2. CB-Tumblebug 기여 방법
3. CB-Tumblebug 실행 방법
4. CB-Tumblebug 소스 빌드 및 실행 방법 상세
5. CB-Tumblebug 기능 사용 방법

CB-Tumblebug 실행 및 개발 환경

- Linux (추천: Ubuntu 22.04)
- Go (추천: v1.21.6)

의존성 리스트 (SBOM)

https://github.com/cloud-barista/cb-tumblebug

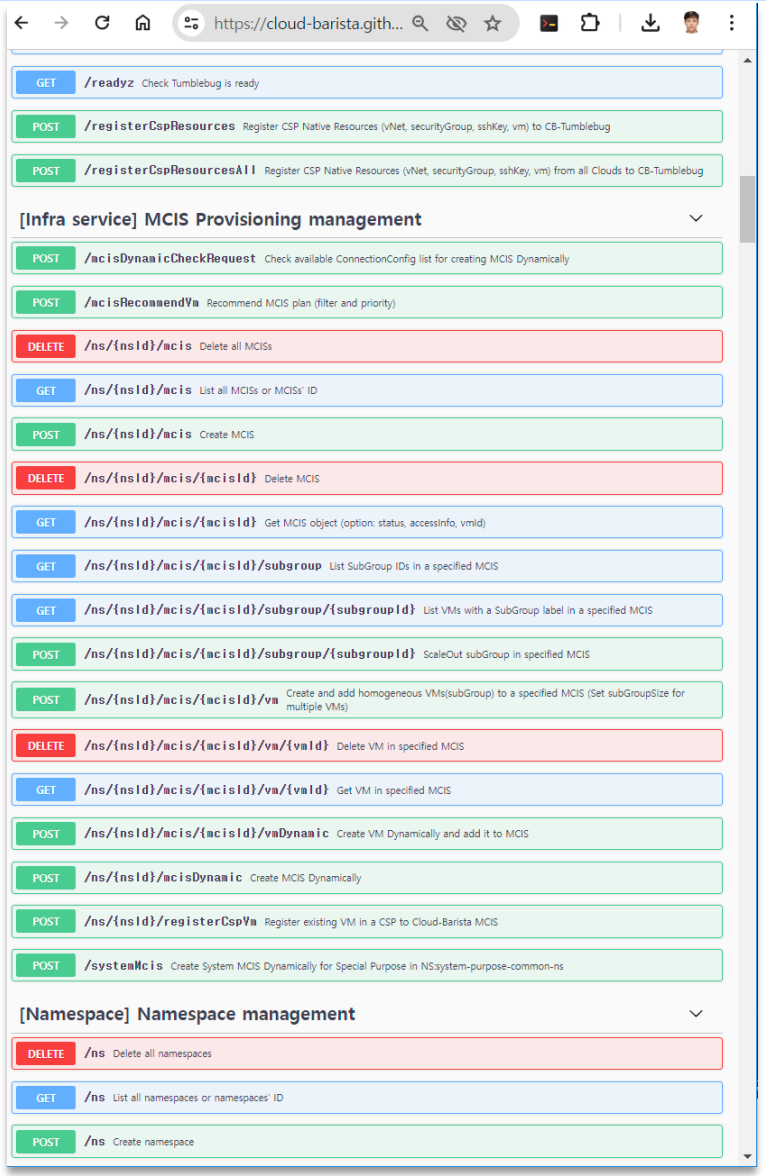

API: 150+

- **라이브 API 상시 공개**
- https://cloud-barista.github.io/api/?url=https://raw.githubusercontent.com/cloud-barista/cb-tumblebug/main/src/api/rest/docs/swagger.yaml

CB-Tumblebug 설치 및 활용 가이드

- 설치 및 실행 방법, API 규격 및 활용 방법 등 세부 내용 참고 : https://github.com/cloud-barista/cb-tumblebug
- REST API 및 활용 개요

  - CB-TB 서버 실행
  - CB-TB 제어
    - REST API
      - CB-MapUI
      - Web Dashboards
    - 스크립트
  - CB-TB 로 생성한 MCIS 맛보기
    - 영상회의 서버 자동 배포
    - FPS, MMORPG 게임 자동 배포
    - Ansible 환경 자동 구성
    - Nginx 자동 배포
    - 클러스터 모니터링 도구 배포
    - …

CB-Tumblebug 서버: REST API/ Swagger API 지원

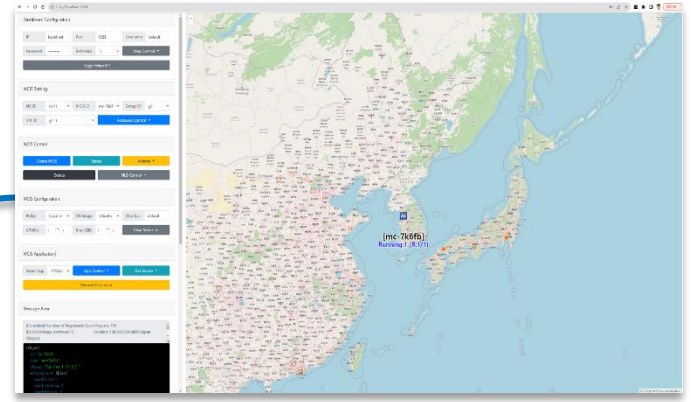

MapUI: 지도 기반 GUI 클라이언트

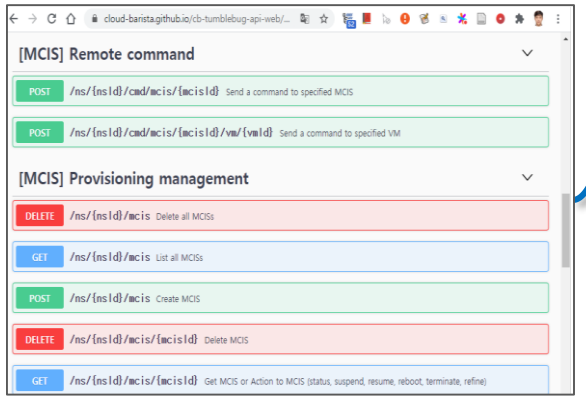

REST API Swagger dashboard

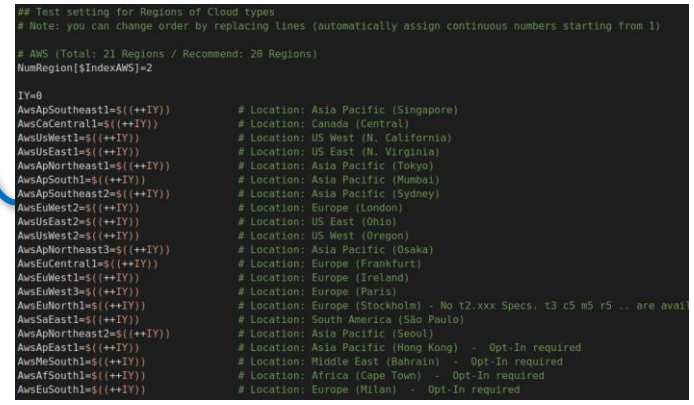

스크립트 기반 시험 자동화 도구

CB-Tumblebug 활용 사례

<최적배치 기반의 멀티 클라우드 기반 영상 회의 서비스>

< 글로벌 스케일 멀티 클라우드 FPS 게임 서비스>

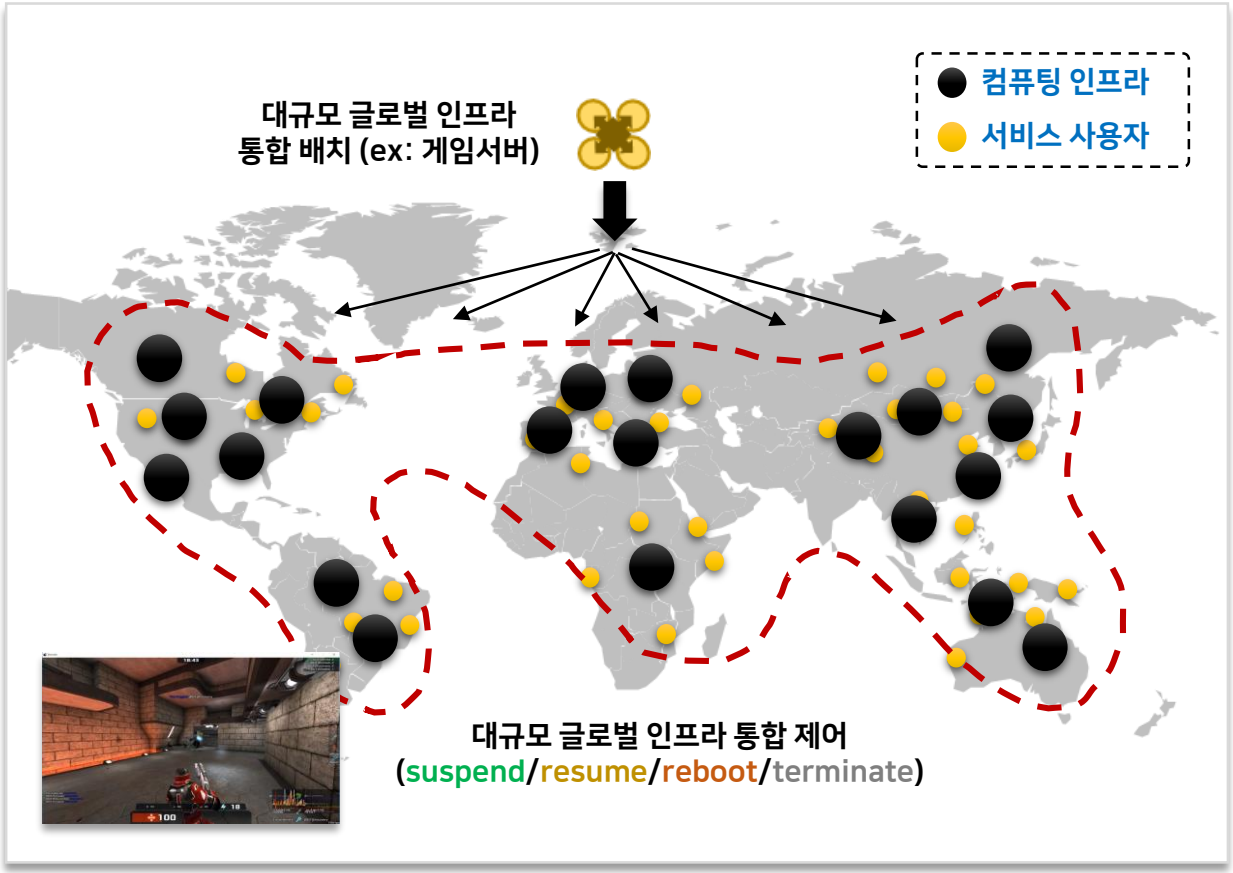

CB-Tumblebug 활용 사례 (글로벌 3D FPS 게임 서비스)


Cloud Barista
클라우드바리스타 커뮤니티 제9차 컨퍼런스
AI 서비스 인프라를 위한 CB-Tumblebug의 여정
Multi-Cloud LLM Service by CB-TB
시나몬 (Cinnamon) 한잔 어떠세요 ?

Cloud Barista

어느 날 갑자기 찾아온 *LLM

*LLM (Large Language Model): 방대한 양의 텍스트 데이터로 훈련된 AI 모델 (프롬프트!)

담당자의 고민..

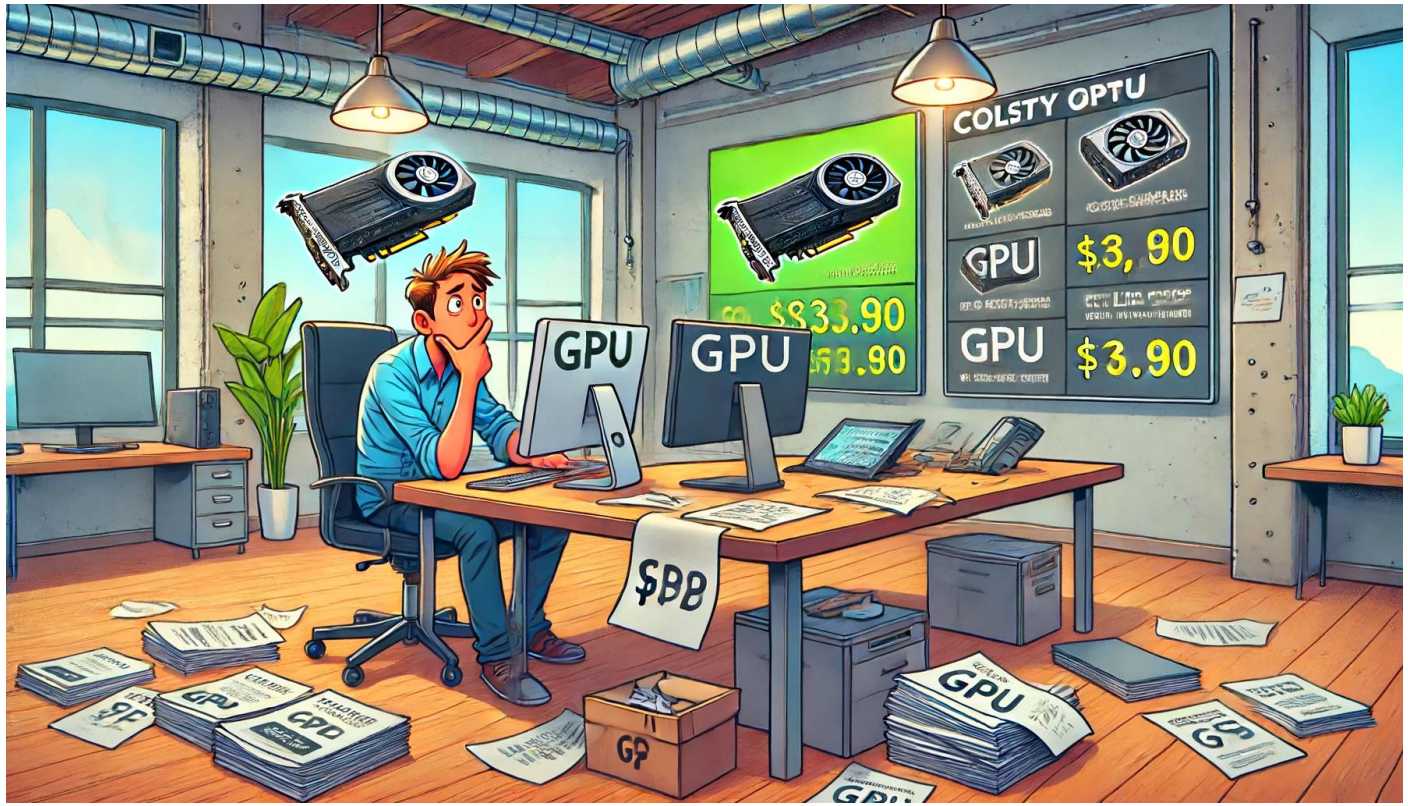

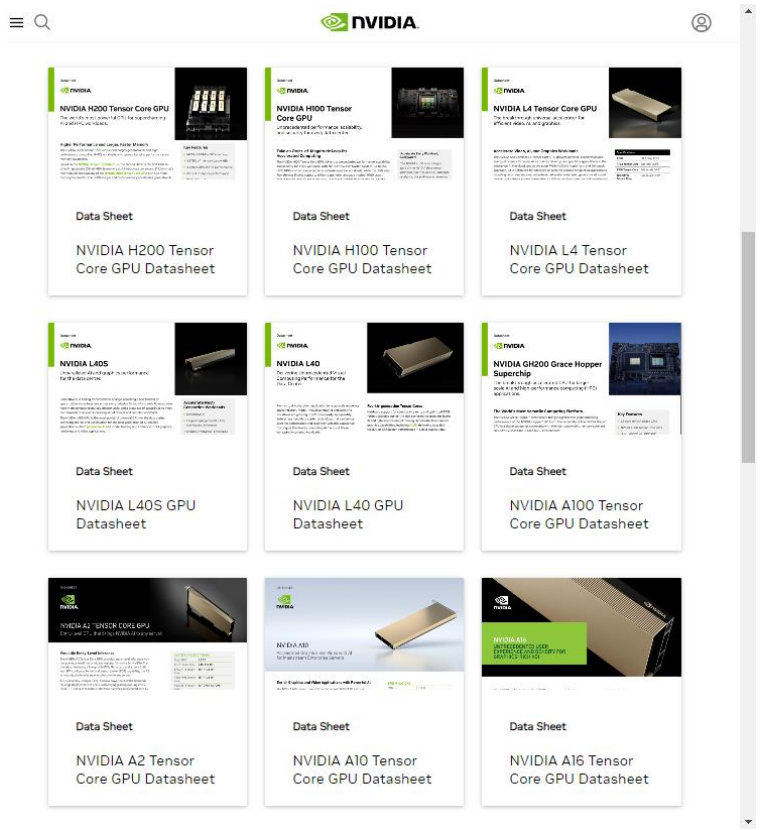

인프라는 어떻게 구축하지? 어떤 GPU를 어떻게 구입하지? GPU 드라이버 설정은 어떻게 하지? ..
LLM은 뭐지? 어떻게 서비스로 배포하지? 비용은 어떻게 하지? 서비스 확장성은 어떻게 제공하지? ..

어떤 GPU를 어떻게 구입하지?

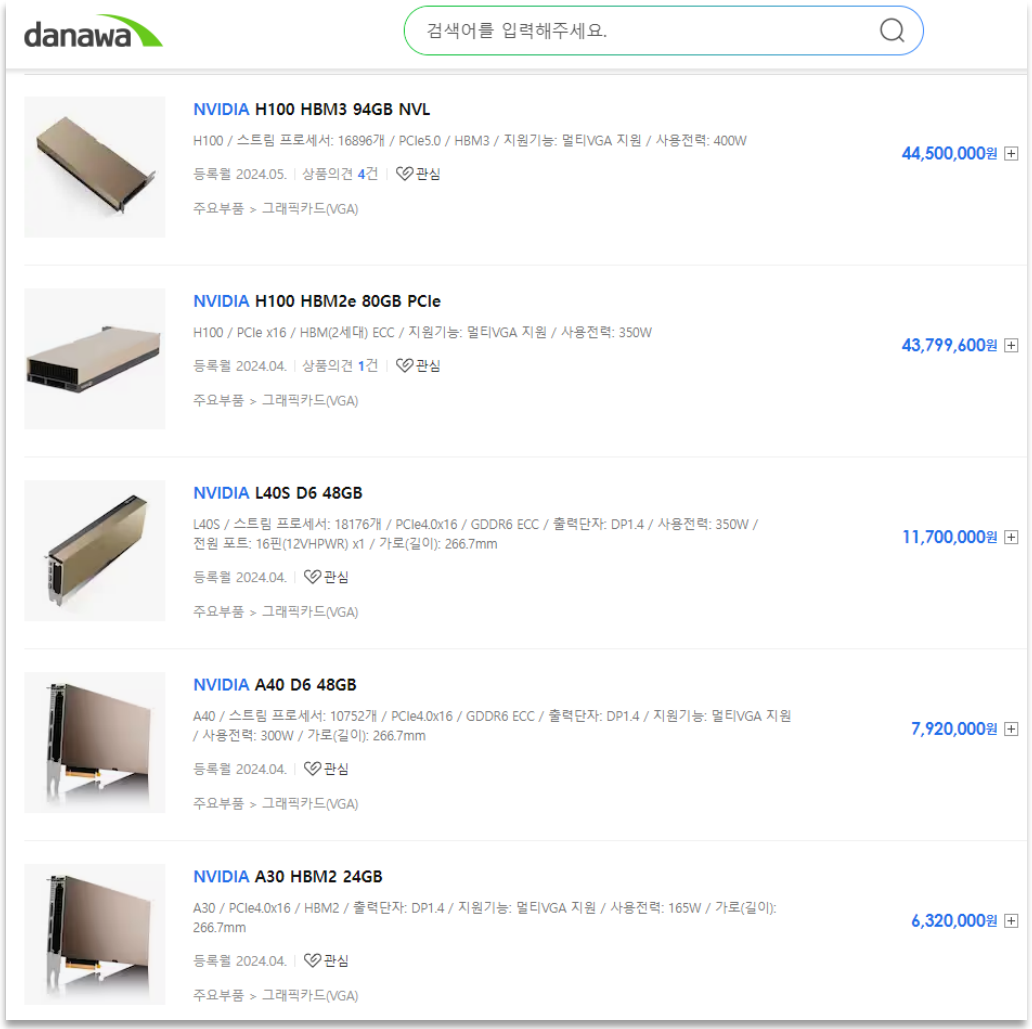

어디서 뭘 사야 하나...

*주문 전 재고 문의 바랍니다.

엔비디아 NVIDIA H100 94GB NVL

구입하기도 어려운 상황?!

챗GPT가 등장한 2022년 말부터 현재까지 AI 칩 부족 현상은 이어지고 있다. 구글, 아마존, 메타 등 빅테크 기업들이 저마다 AI 서비스를 제공하기 위해 엔비디아의 GPU 서버를 대량으로 사들이고 있어서다. 메타는 올해 말까지 H100 35만개를 확보할 예정이며, 마이크로소프트(MS)는 엔비디아 AI 칩 재고를 180만개까지 늘린다는 계획이다.

업계 관계자는 "엔비디아가 AI 칩을 생산하는 데 걸리는 시간(리드타임)이 수개월로 늘어나 공급이 수요를 따라가지 못한 지는 이미 오래"라며 "1년 내내 기다려도 제품을 받지 못하는 기업들도 부지기수"라고 말했다. 오픈AI는 AI 칩 공급 부족 문제를 해결하기 위해 자체 AI 칩을 개발하는 방안을 검토 중이다. 또 MS와 1000억달러(약 134조6000억원)를 들여 AI 슈퍼컴퓨터를 포함한 데이터센터를 구축할 계획을 세우고 있다.

출처: 일론 머스크 "엔비디아 AI 칩 10만개 확보하겠다"… 8조 투자 받고 AI 개발 속도 (ChosunBiz, 2024.05.28.)

LLM은 무엇이고, 어떻게 서비스화 하지?

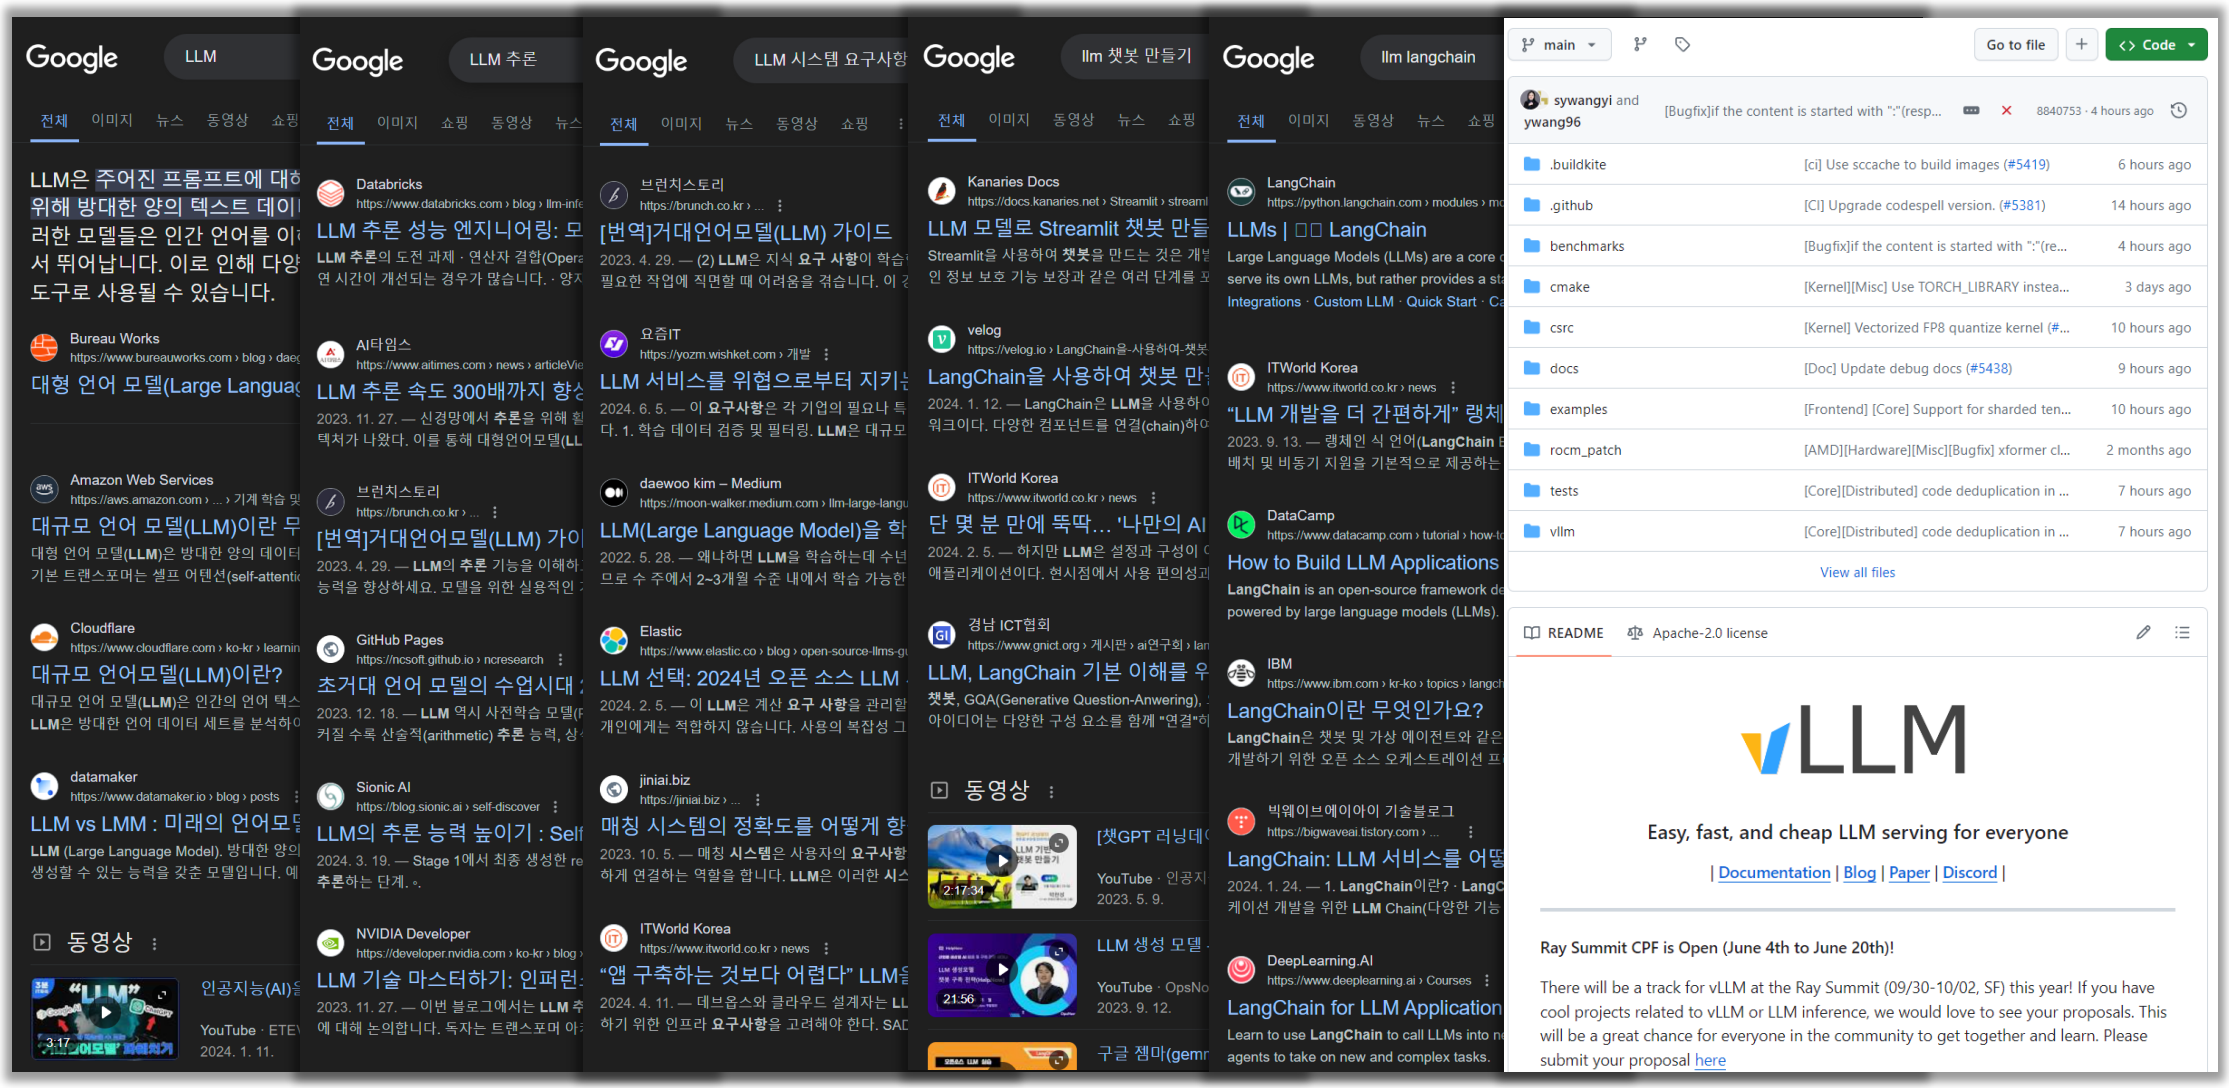

검색 / 스터디 / PoC / 테스트 ..

CB-Tumblebug + GPU x (Ollama + Open WebUI)

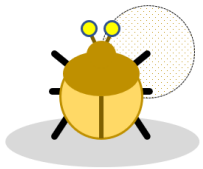

CB-Tumblebug

Depoly and Manage
Multi-Cloud Computing Infra

https://github.com/cloud-barista/cb-tumblebug

Ollama

Open WebUI

vLLM

혹시 같은 고민을 가지고 계셨다면, 이 자리에 잘 오셨습니다. :)

그럼, 열차 출발합니다.

(소요시간: 13분)

SELF HOSTED MULTI-CLOUD LLM BY CB-TUMBLEBUG (&OLLAMA&WEBUI)

Behind the scenes (part 1)

그 동안 어떤 일이 있었을까요?

Back to the 2019

사실은 처음부터..GPU..

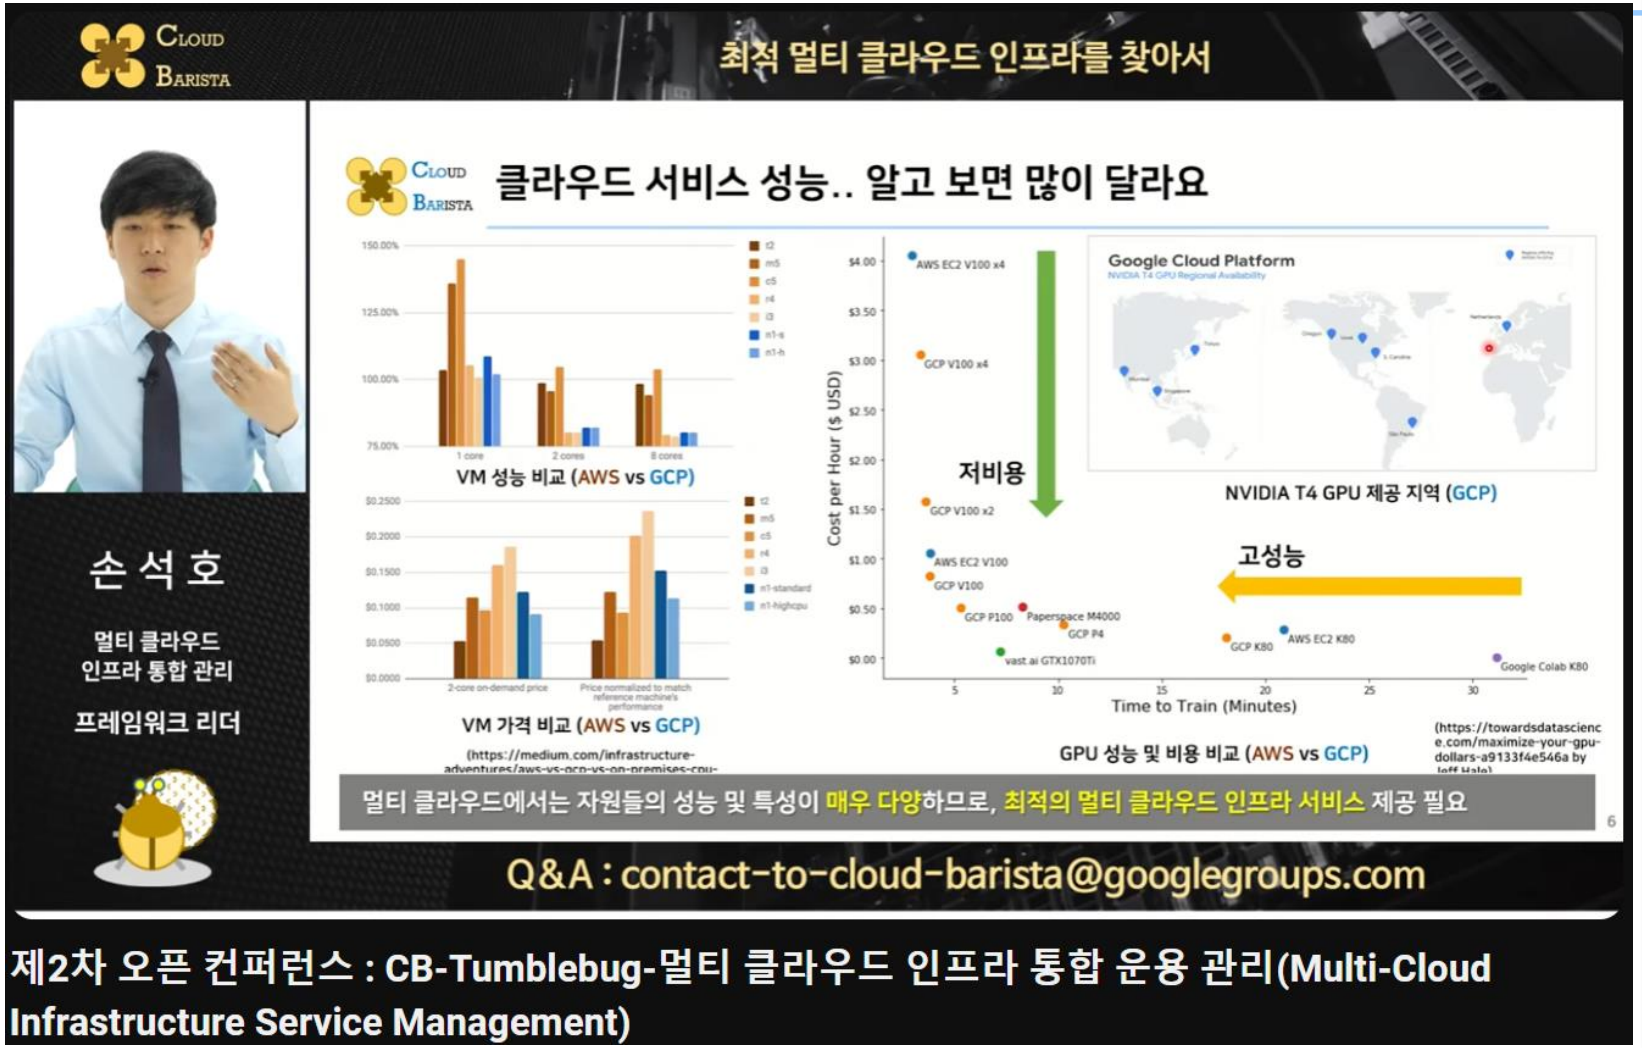

그때 더 팠어야 했는데.. ($: 그때 더 **샀어야** 했는데..)

2,400% ⬆

최적 배치 기능 개선: GPU 등록 및 검색 지원

```
AWS,all,c4.large,0.114,78.3,,,,,,,,,default,default,,,,
AWS,all,c4.4xlarge,0.907,80.74,,,,,,,,,default,default,,,,
AWS,all,c4.2xlarge,0.454,92.55,,,,,,,,,default,default,,,,
AWS,all,g5.xlarge,1.006,34.18,,,,,,,,,default,default,gpu,NVIDIA A10G,1,24,
AWS,all,g5.2xlarge,1.212,67.18,,,,,,,,,default,default,gpu,NVIDIA A10G,1,24,
AWS,all,g5.4xlarge,1.624,78.18,,,,,,,,,default,default,gpu,NVIDIA A10G,1,24,
AWS,all,g5.8xlarge,2.448,89.18,,,,,,,,,default,default,gpu,NVIDIA A10G,1,24,
AWS,all,g5.12xlarge,5.672,99.18,,,,,,,,,default,default,gpu,NVIDIA A10G,1,24,
AWS,all,p4d.24xlarge,32.77,99.88,,,,,,,,,default,default,gpu,NVIDIA A100,1,320,
azure,all,Standard_B1s,0.0132,33.85,,,,,,,,,default,default,,,,
azure,all,Standard_B1ms,0.0264,33.85,,,,,,,,,default,default,,,,
```

github.com/cloud-barista/cb-tumblebug/blob/main/assets/cloudspec.csv

```
AWS,ap-northeast-1,ami-039ed92b1a75d78cc,Debian 10,,
AWS,ap-northeast-1,ami-006b8cbbcbb9386e7,Windows Server 2012 R2,,
AWS,ap-northeast-1,ami-0bded5720a0796acb,Ubuntu 20.04,Deep Learning OSS Nvidia Driver
AMI GPU TensorFlow 2.15 (Ubuntu 20.04) 20240423,G4dn G5 G6 Gr6 P4 P4de P5
AWS,ap-south-1,ami-0123b531fc646552f,Ubuntu 18.04,,
AWS,ap-south-1,ami-068257025f72f470d,Ubuntu 22.04,,
```

github.com/cloud-barista/cb-tumblebug/blob/main/assets/cloudimage.csv

- GPU 입력 가능하게 정보 확장
- Spec, Image가 순차적으로 등록 및 테스트 진행되고 있음 (아직 제한적, 3 CSP++)

최적 배치 기능 개선: GPU 등록 및 검색 지원

commonSpec ID 획득 방식 개선

/mcisRecommendVm 필터링 옵션 확대

- 기존
  - 산술 조건: cpu, memory, cost
  - 문자열 조건: provider, region, specname
  - 확장시 소스에서 조건 개별 추가
- 개선
  - 산술 조건 & 문자열 조건:
    Spec Object Struct의 모든 항목 활용 가능
  - 확장시 개별 조건 추가 필요 없음
    (내부적: type 동적 판별을 위한 reflect)

- /mcisRecommendVm API를 사용하면, 사용자가 요청한 사양 및 조건에 맞는 Spec 리스트를 획득할 수 있음
- 필터링 및 우선순위가 적용 가능하며, 다양한 파라미터의 조합이 가능하므로 별도의 옵션을 알고 사용할 필요.

필터링 옵션

ex: "metric": "providerName"

산술 일치 조건 "<=", ">=", "==" (ex: "operator": "<=", "operand": "4")

- VCPU `json:"vCPU"`
- MemoryGiB `json:"memoryGiB"`
- CostPerHour `json:"costPerHour"`
- AcceleratorCount `json:"acceleratorCount"`
- AcceleratorMemoryGB `json:"acceleratorMemoryGB"`

문자열 포함 조건 (ex: "operand": "gcp")

- ProviderName `json:"providerName"`
- RegionName `json:"regionName"`
- CspSpecName `json:"cspSpecName"`
- AcceleratorModel `json:"acceleratorModel"`
- AcceleratorType `json:"acceleratorType"`
- Description `json:"description"`

https://github.com/cloud-barista/cb-tumblebug/discussions/1234

무한 Testing & Scripting (NVIDIA+Cuda, Ollama, Open WebUI)

잘 될 때까지 잘 되게 하라 (아마도 아직 부족..)

cb-tumblebug / scripts / usecases / llm /

seokho-son Fix echo for Update deployOpenWebUI.sh

Name	Last commit message
..	
README.md	Update llm readme
deployOllama.sh	Remove disabled echo function in deployOllama.sh
deployOpenWebUI.sh	Fix echo for Update deployOpenWebUI.sh
installCudaDriver.sh	Update installCudaDriver.sh
llmServer.py	Fix model agrs bug in the llm script
startServer.sh	Update startServer.sh
statusServer.sh	Ehance llm usecase code
stopServer.sh	Update llm usecase with easy setting

github.com/cloud-barista/cb-tumblebug/tree/main/scripts/usecases/llm

Model library

Ollama supports a list of models available on ollama.com/library

Here are some example models that can be downloaded:

Model	Parameters	Size	Download
Llama 3	8B	4.7GB	`ollama run llama3`
Llama 3	70B	40GB	`ollama run llama3:70b`
Phi 3 Mini	3.8B	2.3GB	`ollama run phi3`
Phi 3 Medium	14B	7.9GB	`ollama run phi3:medium`
Gemma	2B	1.4GB	`ollama run gemma:2b`
Gemma	7B	4.8GB	`ollama run gemma:7b`
Mistral	7B	4.1GB	`ollama run mistral`
Moondream 2	1.4B	829MB	`ollama run moondream`
Neural Chat	7B	4.1GB	`ollama run neural-chat`
Starling	7B	4.1GB	`ollama run starling-lm`
Code Llama	7B	3.8GB	`ollama run codellama`
Llama 2 Uncensored	7B	3.8GB	`ollama run llama2-uncensored`
LLaVA	7B	4.5GB	`ollama run llava`
Solar	10.7B	6.1GB	`ollama run solar`

> Note: You should have at least 8 GB of RAM available to run the 7B models, 16 GB to run the 13B models, and 32 GB to run the 33B models.

Ollama 지원 LLM 모델 (일부)

원격 커맨드 개선: 다중 커맨드 / 빌트인 함수 지원

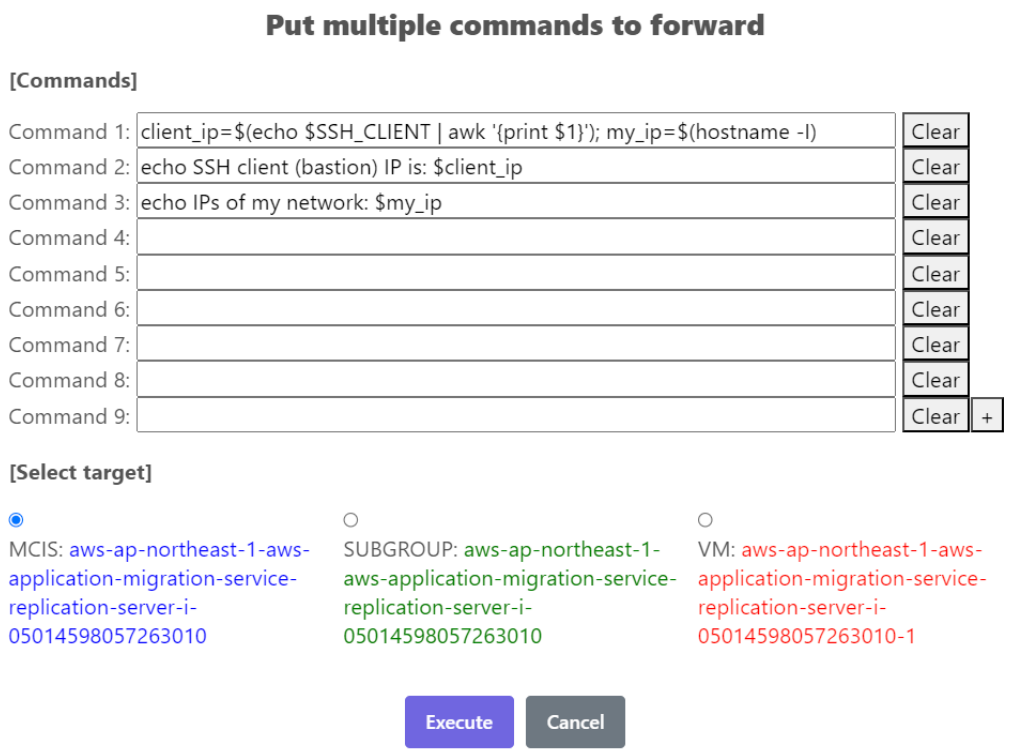

- 빌트인 키워드: $$Func()
  - target 리소스 지정 방식
    - this: 커맨드가 실행될 스스로를 명시
    - mcis.vm 패턴: 리소스를 "." 으로 구분하여 명시
  - prefix, postfix, separator
    - 앞뒤에 스트링 추가, 리스트를 구분자포함 스트링으로 변경
- 빌트인 함수
  - GetPublicIP: 커맨드가 실행되는 자신(또는 명시한 VM)의 IP 스트링으로 교체
    - $$Func(GetPublicIP(target=this, prefix=http://, postfix=:3000))
      ➔ http://3.15.18.101:3000
  - GetPublicIPs: 커맨드가 실행되는 자신(또는 명시한 MCIS) 의 IP 스트링으로 교체
    - $$Func(GetPublicIP(target=this, separator=+, postfix=:3000))
      ➔ 3.15.18.101:3000 + 5.25.153.31:3000 + 7.215.23.33:3000
  - AssignTask: MCIS 내의 각 VM에 지정된 Task 리스트 내의 Task를 할당
    - $$Func(AssignTask(task='llama3, solar, mistral, phi3, gemma, mixtral, llava, yi, falcon2, llama2'))
      ➔ VM1: llama3 , VM2: solar, VM3: mistral, ···

시스템 개선: safe startup

- 개요
  - CB-TB 초기화시, CB-SP에 자동 초기화 작업 진행 개선
  - 연결 및 활성화된 CB-SP가 없으면 CB-TB 오류 발생
- 개선 사항
  - CB-TB 서버 실행시, CB-SP Health check (API: readyz)
    - 3초 단위로 60회 시도
    - 180초 내에 확인되지 않으면, 서버 종료

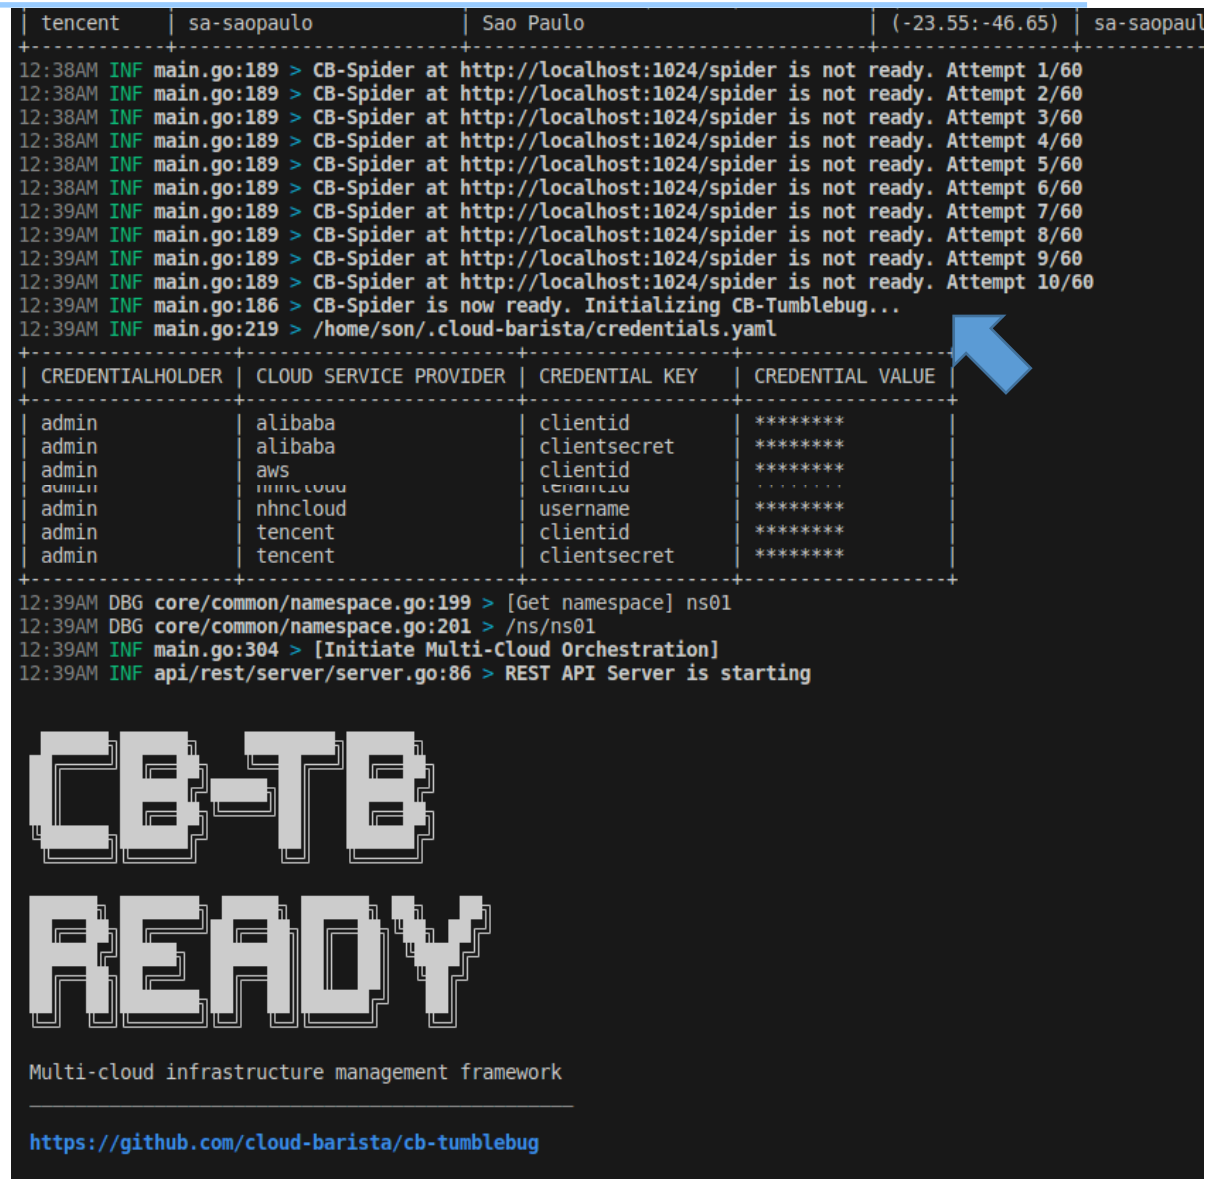

시스템 개선: 시스템 초기화, 고도화 (init.py)

```
Checking server health...
Tumblebug Server is healthy.

Registering credentials and Loading common Specs and Images takes time
Do you want to proceed ? (y/n) : y

Registering all valid credentials for all cloud regions...
- ibm: {'credentialName': 'ibm', 'credentialHolder': 'admin', 'providerName': 'ibm', 'keyValueInfoList': [{'key': 'ApiKey', 'value': '************'}]
}
- alibaba: {'credentialName': 'alibaba', 'credentialHolder': 'admin', 'providerName': 'alibaba', 'keyValueInfoList': [{'key': 'ClientId', 'value': '*
***********'}, {'key': 'ClientSecret', 'value': '************'}]}
- aws: {'credentialName': 'aws', 'credentialHolder': 'admin', 'providerName': 'aws', 'keyValueInfoList': [{'key': 'ClientId', 'value': '************'
}, {'key': 'ClientSecret', 'value': '************'}]}
- gcp: {'credentialName': 'gcp', 'credentialHolder': 'admin', 'providerName': 'gcp', 'keyValueInfoList': [{'key': 'client_id', 'value': '************
'}, {'key': 'ClientEmail', 'value': '************'}, {'key': 'private_key_id', 'value': '************'}, {'key': 'PrivateKey', 'value': '************
'}, {'key': 'ProjectID', 'value': '************'}]}
- azure: {'credentialName': 'azure', 'credentialHolder': 'admin', 'providerName': 'azure', 'keyValueInfoList': [{'key': 'ClientId', 'value': '*******
*****'}, {'key': 'ClientSecret', 'value': '************'}, {'key': 'TenantId', 'value': '************'}, {'key': 'SubscriptionId', 'value': '********
****'}]}
- ktcloud: {'credentialName': 'ktcloud', 'credentialHolder': 'admin', 'providerName': 'ktcloud', 'keyValueInfoList': [{'key': 'ClientId', 'value': '*
***********'}, {'key': 'ClientSecret', 'value': '************'}]}
- openstack: Incomplete credential data, Skip
- ncp: {'credentialName': 'ncp', 'credentialHolder': 'admin', 'providerName': 'ncp', 'keyValueInfoList': [{'key': 'ClientId', 'value': '************'
}, {'key': 'ClientSecret', 'value': '************'}]}
- ktcloudvpc: {'credentialName': 'ktcloudvpc', 'credentialHolder': 'admin', 'providerName': 'ktcloudvpc', 'keyValueInfoList': [{'key': 'IdentityEndpo
int', 'value': '************'}, {'key': 'Username', 'value': '************'}, {'key': 'Password', 'value': '************'}, {'key': 'ClientId', 'valu
e': '************'}, {'key': 'ClientSecret', 'value': '************'}, {'key': 'DomainName', 'value': '************'}, {'key': 'ProjectID', 'value':
'************'}]}
- ncpvpc: {'credentialName': 'ncpvpc', 'credentialHolder': 'admin', 'providerName': 'ncpvpc', 'keyValueInfoList': [{'key': 'ClientId', 'value': '****
********'}, {'key': 'ClientSecret', 'value': '************'}]}
- nhncloud: {'credentialName': 'nhncloud', 'credentialHolder': 'admin', 'providerName': 'nhncloud', 'keyValueInfoList': [{'key': 'IdentityEndpoint',
'value': '************'}, {'key': 'Username', 'value': '************'}, {'key': 'Password', 'value': '************'}, {'key': 'DomainName', 'value':
'************'}, {'key': 'TenantId', 'value': '************'}]}
- tencent: {'credentialName': 'tencent', 'credentialHolder': 'admin', 'providerName': 'tencent', 'keyValueInfoList': [{'key': 'ClientId', 'value': '*
***********'}, {'key': 'ClientSecret', 'value': '************'}]}

Loading common Specs and Images...

Progress: 100%|                                                                                | 240/240 [03:39<00:00,  1.09s/s]

Loading completed (3.65 minutes)
Registered Common specs
- Successful: 3363, Failed: 1354
Registered Common images
- Successful: 467, Failed: 128

Cleaning up...
Environment cleanup complete.
son@son:~/go/src/github.com/cloud-barista/cb-tumblebug$
```

bash cb-tumblebug
npm cb-mapui
bash cb-tumblebug

지원 대상 확대: 국내 CSP 프로비저닝 지원

CB-TB 국내 CSP 지원 시연
(MCIS 통합 제어)

Behind the scenes (part 2)

아직 잘 안되는 포인트

H100 생성, 실패 : 사용자 자원 쿼터 부족 (AWS)

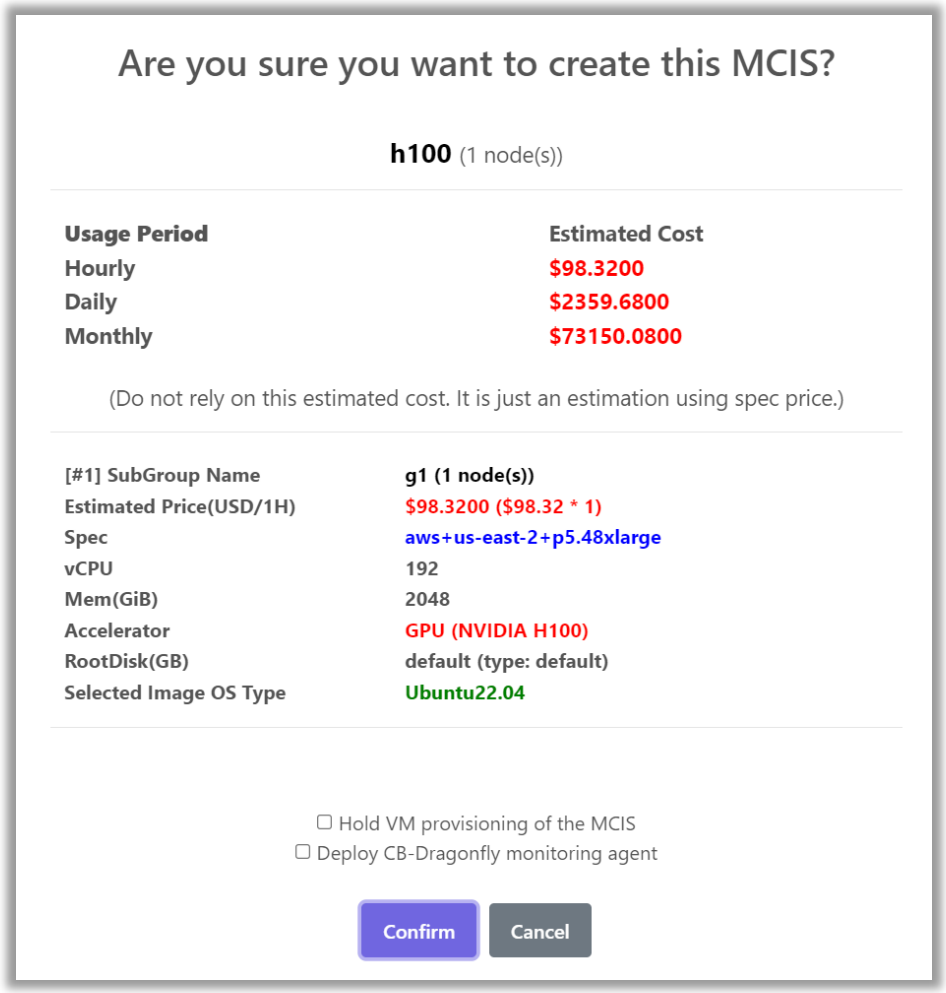

Status: Failed

VcpuLimitExceeded: You have requested more vCPU capacity than your current vCPU limit of 64 allows for the instance bucket that the specified instance type belongs to.

Please visit http://aws.amazon.com/contact-us/ec2-request to request an adjustment to this limit.

사용자 자원 쿼터 부족 (AWS)

Recommended Spec and CSP region

Recommended Spec	p5.48xlarge
Estimated Price(USD/1H)	$ 98.32 (at least)
Selected Image OS Type	Ubuntu22.04

Provider	AWS
Region	us-east-2
ConnectionConfig	aws-us-east-2
------	
vCPU	192
Mem(GiB)	2048
RootDiskType	default
RootDiskSize(GB)	default

AcceleratorType	GPU
AcceleratorModel	NVIDIA H100
AcceleratorCount	8
AcceleratorMemoryGB	640

Show All Recommendations

Enter the number of VMs for scaling (1 ~ 10)

1

Confirm Cancel

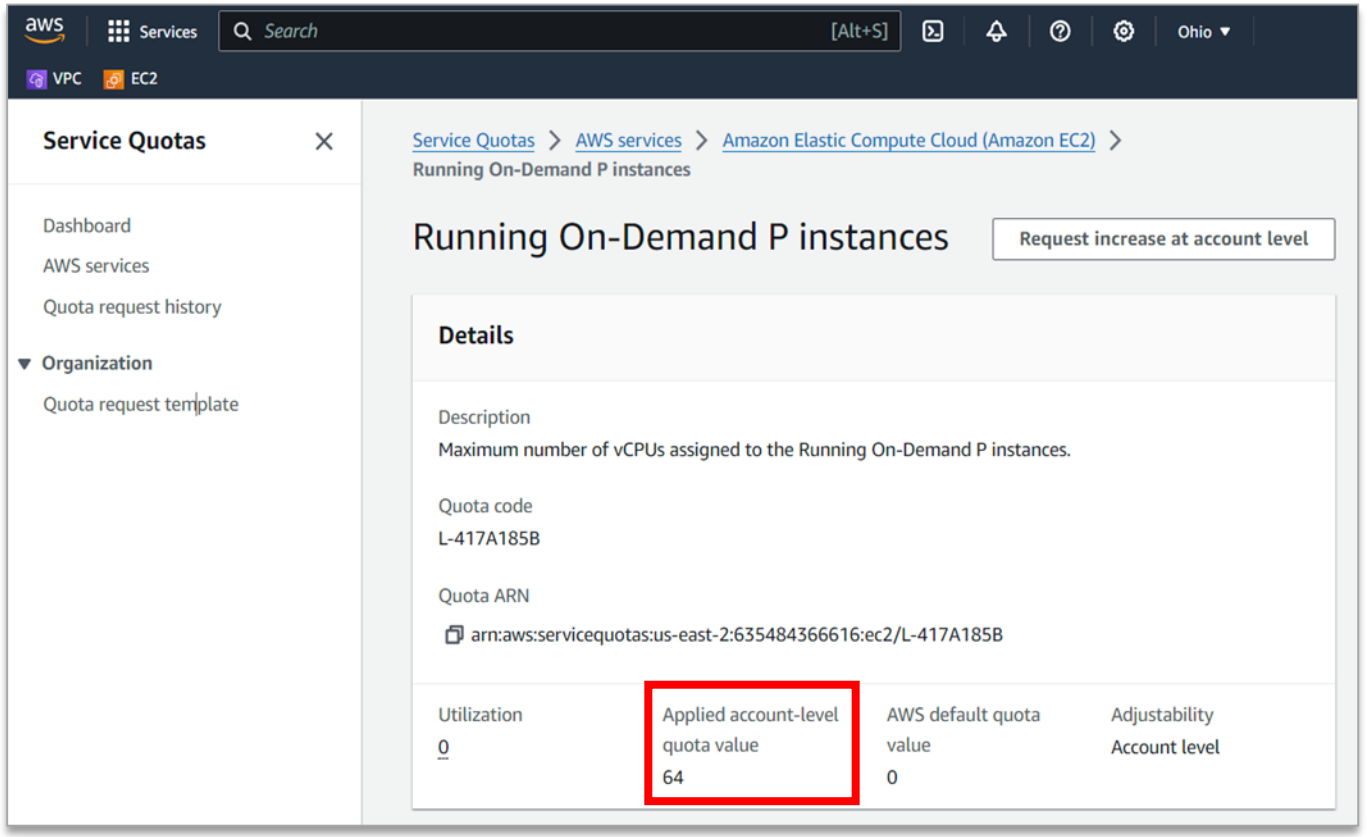

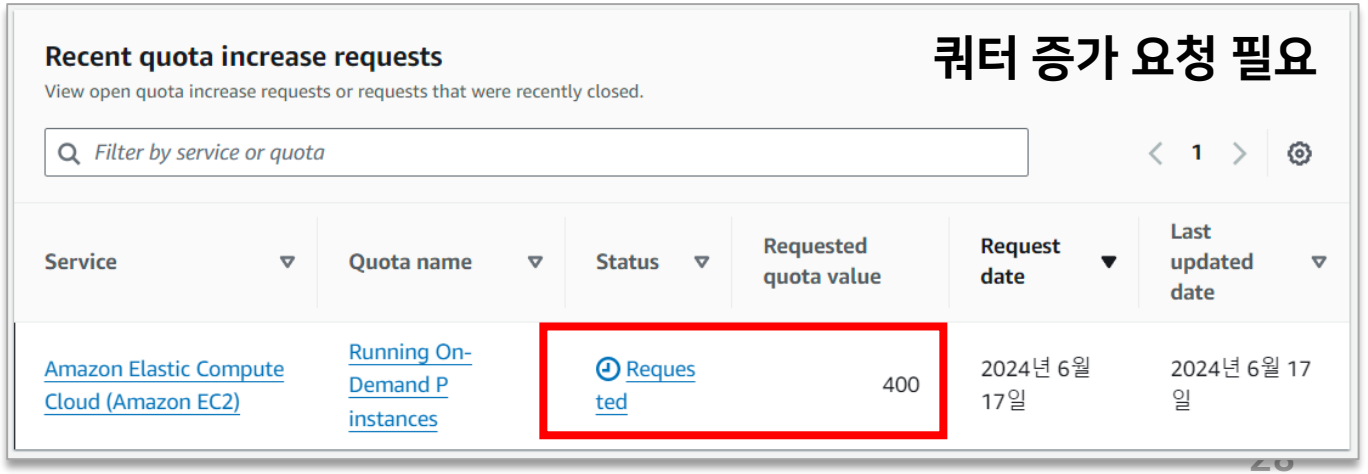

사용자 자원 쿼터 부족 (GCP, Azure, … 마찬가지)

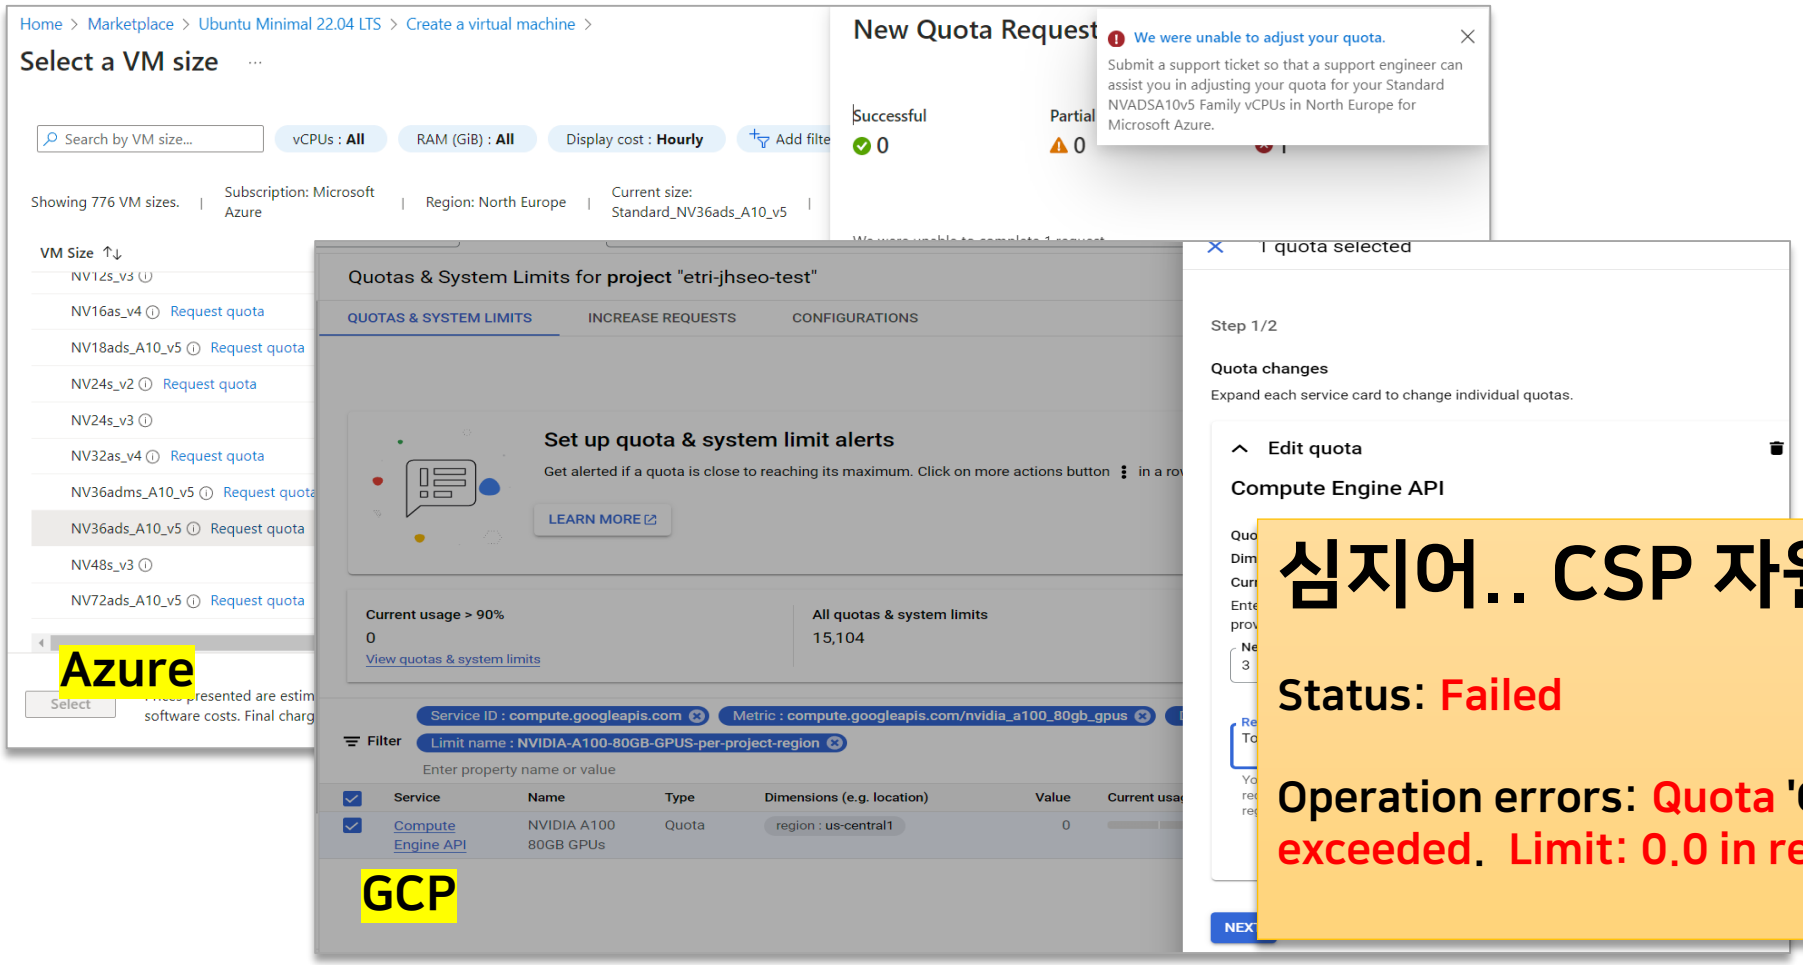

방도가..

심지어.. CSP 자원 부족 (H/A100)

Status: Failed

Operation errors: Quota 'GPUS_PER_GPU_FAMILY' exceeded. Limit: 0.0 in region us-west4

LLM 배포 관련 스크립트의 제약! (급하게 만드느라..)

cb-tumblebug / scripts / usecases / llm / installCudaDriver.sh

seokho-son Update installCudaDriver.sh ✓ 56b32cd · 2 days ago History

Code Blame 75 lines (62 loc) · 2.77 KB · Raw

```
#!/bin/bash

# This script installs NVIDIA drivers and CUDA on Ubuntu 22.04.
# It downloads necessary files from NVIDIA's official website,
# installs the drivers and CUDA, sets the required environment variables,
# and reboots the system to apply changes.
# https://developer.nvidia.com/cuda-downloads?target_os=Linux&target_arch=x86_64&Distribution=Ubu

# Check for NVIDIA GPU
echo "Checking for NVIDIA GPU..."
GPU_INFO=$(sudo lspci | grep -i nvidia)
if [ -z "$GPU_INFO" ]; then
  echo "No NVIDIA GPU detected or an error occurred. Exiting..."
  sudo lspci
  exit 1
else
  echo "NVIDIA GPU detected:"
  echo "$GPU_INFO"
  echo "Check root disk size"
  df -h / | awk '$NF=="/" {print "Total: "$2, "Available: "$4}'
```

- 현재! 깡통 Ubuntu 22.04만 지원합니다!
- Sustainable 하지 않습니다!
- CSP 이미지를 사용하면 좋겠지만, 찾는 것도 일입니다.

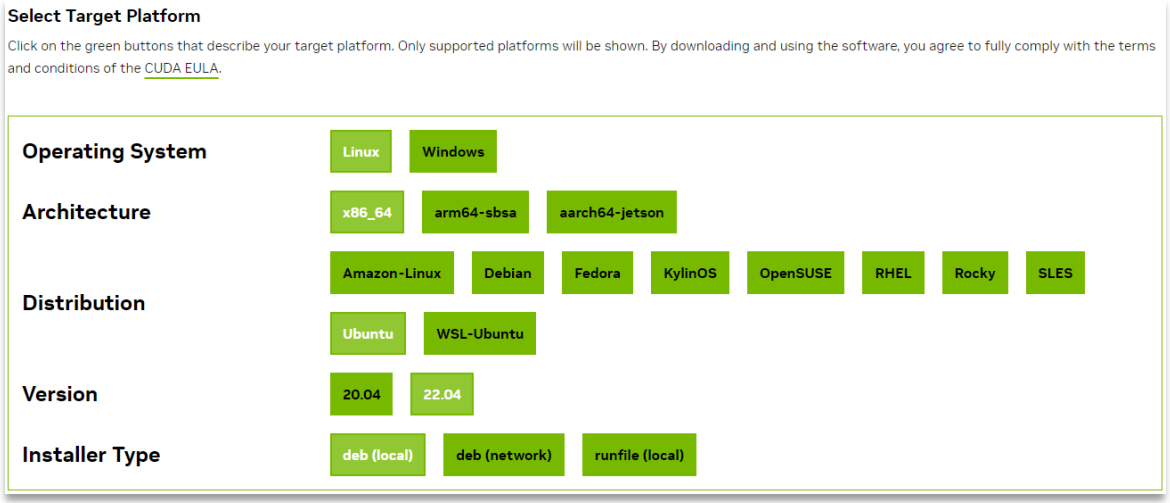

github.com/cloud-barista/cb-tumblebug/blob/main/scripts/usecases/llm/installCudaDriver.sh

developer.nvidia.com/cuda-downloads

오류. 기타 등등 (이제는 조심해야!)

파산 방지

정확하지 않은 추정 가격이라도

GUI에 급히 추가한 이유가 있습니다.

(시스템 로그에도 좀 더 신경 썼습니다. ++ZeroLog)

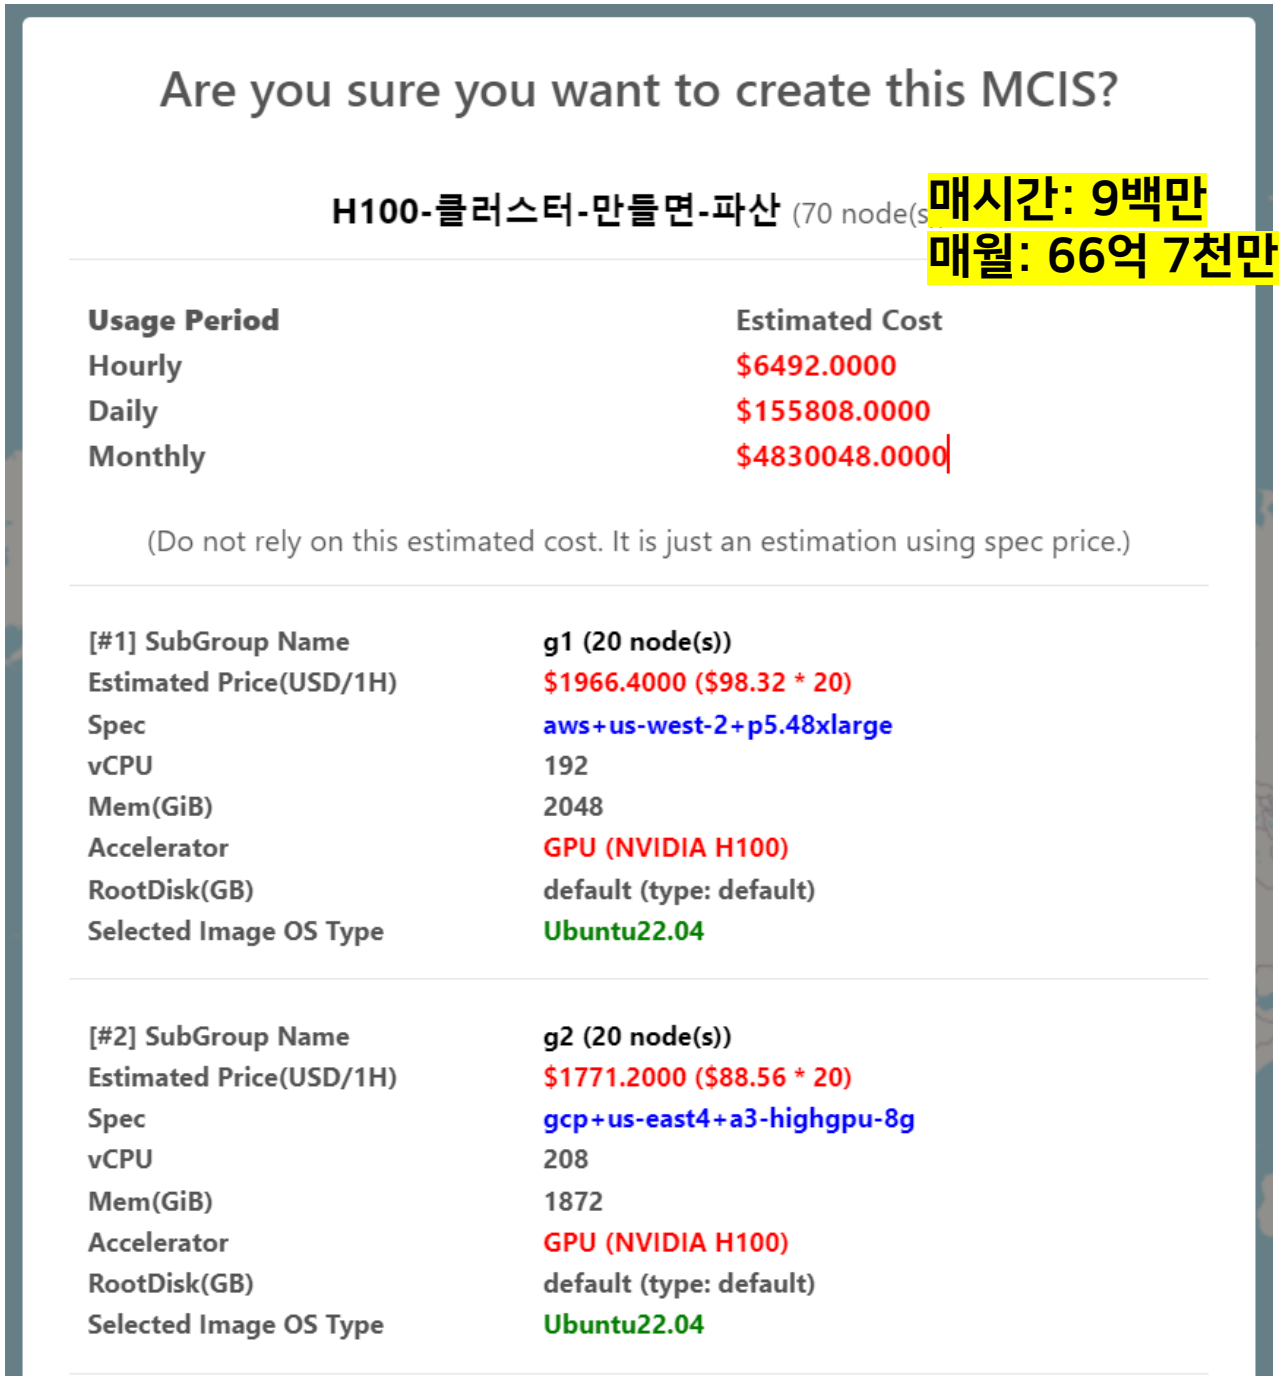

아직은 단순한 인프라 구성. 최적화는..언제쯤..

NVIDIA Data Center Products

GPU	Compute Capability
NVIDIA H100	9.0
NVIDIA L4	8.9
NVIDIA L40	8.9
NVIDIA A100	8.0
NVIDIA A40	8.6
NVIDIA A30	8.0
NVIDIA A10	8.6
NVIDIA A16	8.6
NVIDIA A2	8.6
NVIDIA T4	7.5
NVIDIA V100	7.0
Tesla P100	6.0
Tesla P40	6.1
Tesla P4	6.1
Tesla M60	5.2
Tesla M40	5.2
Tesla K80	3.7
Tesla K40	3.5
Tesla K20	3.5
Tesla K10	3.0

Table 21: Technical Specifications per Compute Capability

	Compute Capability													
Technical Specifications	5.0	5.2	5.3	6.0	6.1	6.2	7.0	7.2	7.5	8.0	8.6	8.7	8.9	9.0
Maximum number of resident grids per device (Concurrent Kernel Execution)	32		16	128	32	16	128	16	128					
Maximum dimensionality of grid of thread blocks	3													
Maximum x -dimension of a grid of thread blocks [thread blocks]	2^{31}-1													
Maximum y- or z-dimension of a grid of thread blocks	65535													
Maximum dimensionality of thread block	3													
Maximum x- or y-dimensionality of a block	1024													
Maximum z-dimension of a block	64													
Maximum number of threads per block	1024													
Warp size	32													
Maximum number of resident blocks per SM	32								16	32	16		24	32
Maximum number of resident warps per SM	64								32	64	48			64
Maximum number of resident threads per SM	2048								1024	2048	1536			2048
Number of 32-bit registers per SM	64 K													
Maximum number of 32-bit registers per thread block	64 K		32 K	64 K		32 K	64 K							
Maximum number of 32-bit registers per thread	255													
Maximum amount of shared memory per SM	64 KB	96 KB	64 KB		96 KB	64 KB			64 KB	164 KB	100 KB	164 KB	100 KB	228 KB
Maximum amount of shared memory per thread block [32]	48 KB													227 KB
Number of shared memory banks														
Maximum amount of local memory per thread														
Constant memory size	64 KB													
Cache working set per SM for constant memory	8 KB			4 KB										
Cache working set per SM for texture memory	Between 12 KB and 48 KB			Between 24 KB and					64 KB	KB ~ 192 KB	28 KB ~ 128 KB	28 KB ~ 192 KB	28 KB ~ 128 KB	28 KB ~ 256 KB
Maximum width for a 1D texture object using a CUDA	65536			131072										

Compute Capability
다양한 결정 요소 (NVIDIA)

.. 연구 필요..

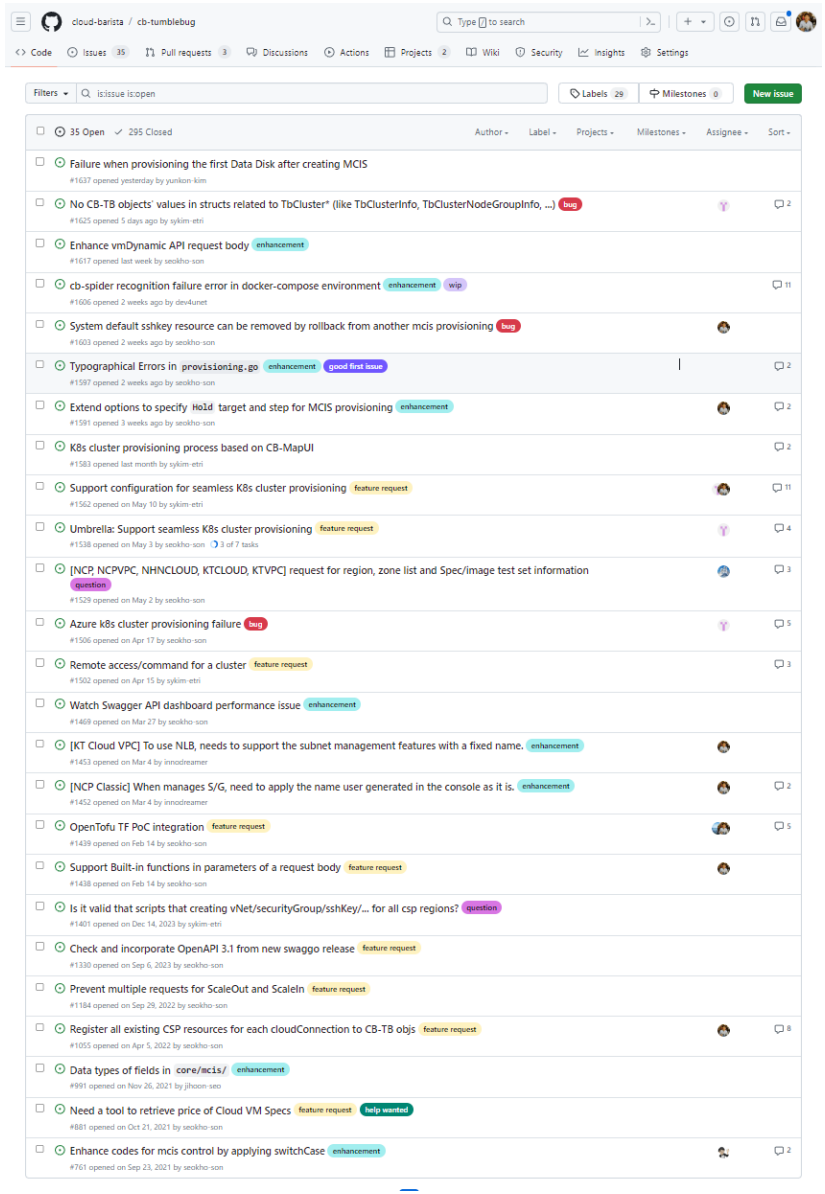

github.com/cloud-barista/cb-tumblebug/issues

사실은.. 아직 해야 할 게 너무 많아요..

(힘들어 죽겠어요..)

살려주세요.

Please.. 😂

So, we need you !
(not just a new feature)

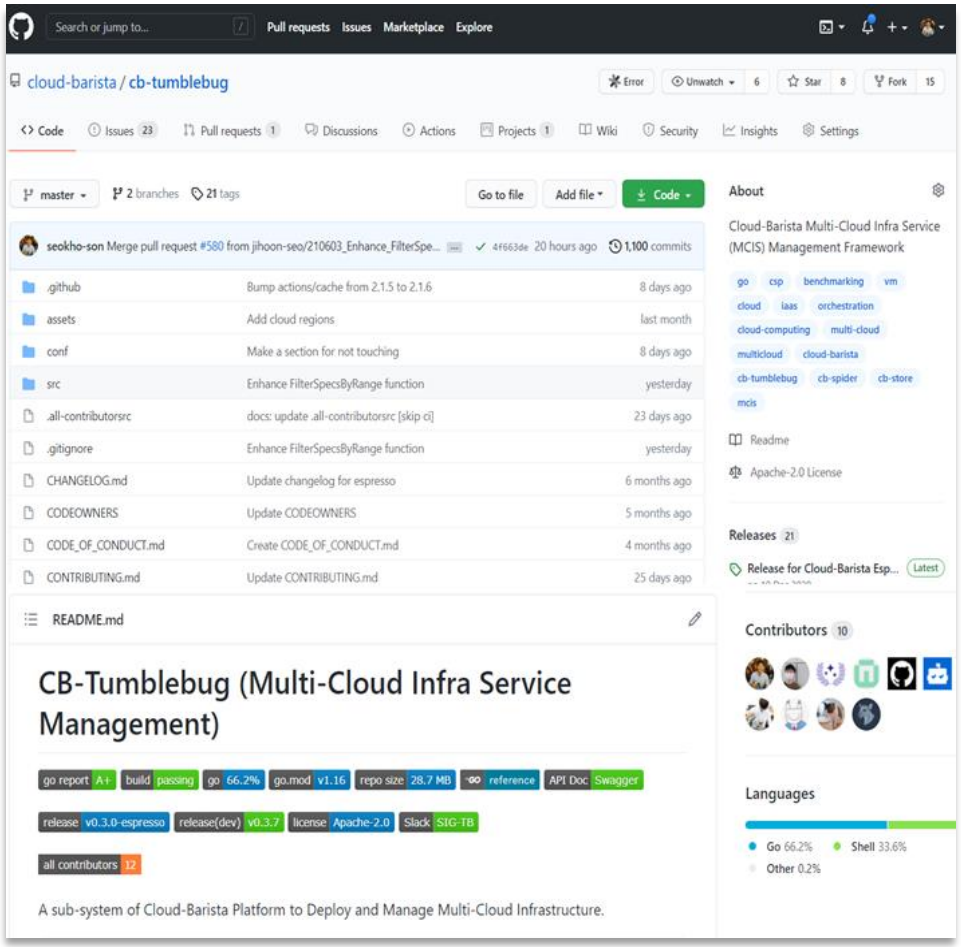

CB-Tumblebug GitHub

https://github.com/cloud-barista/cb-tumblebug

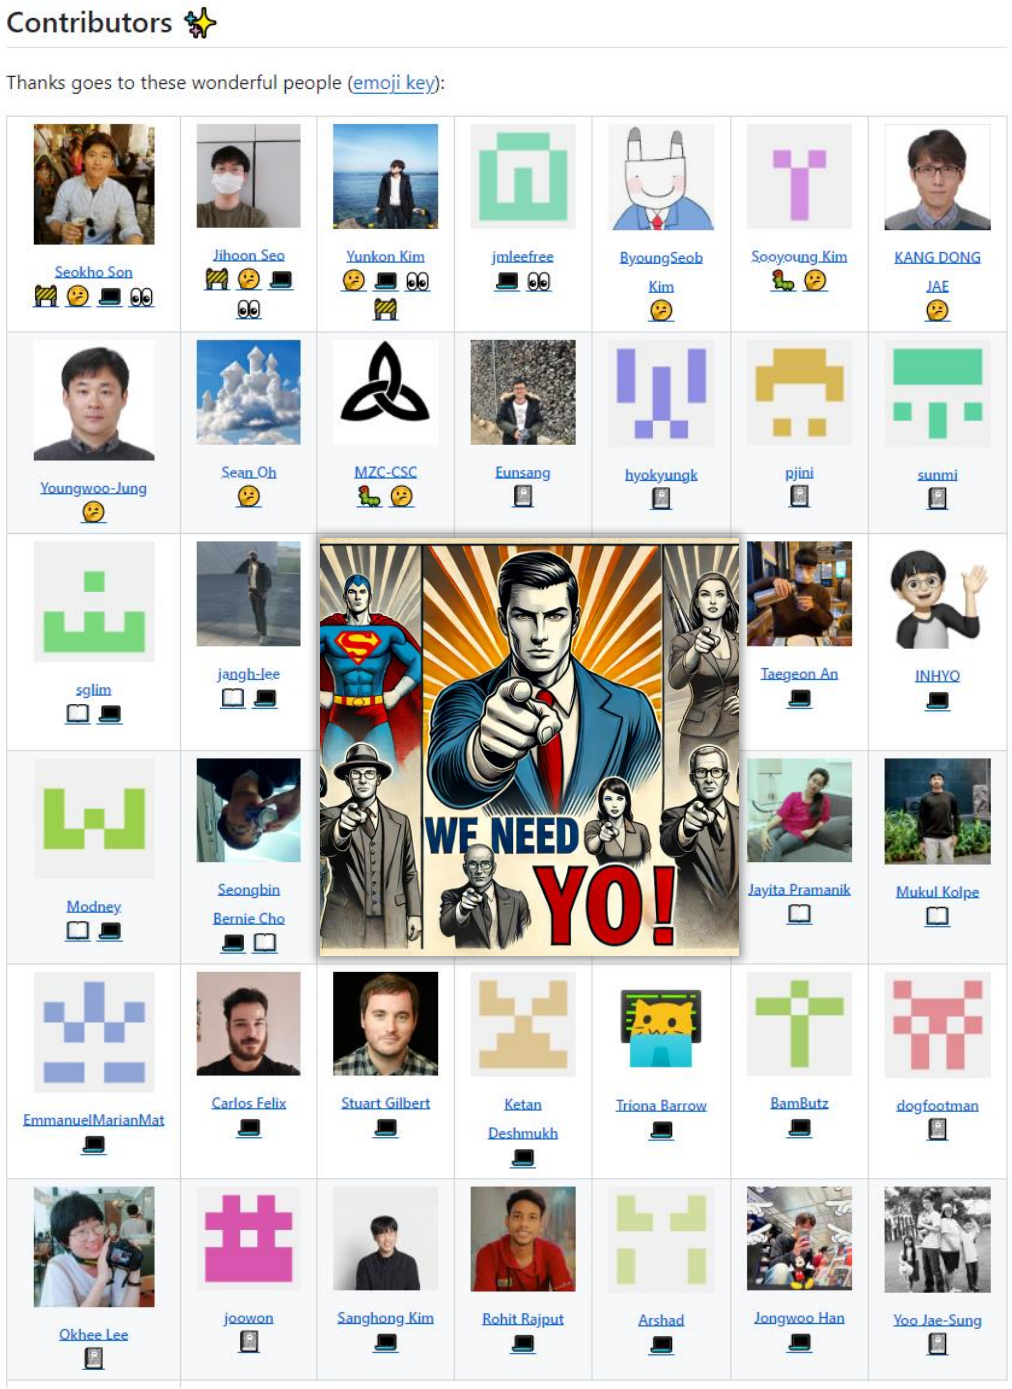

Thank you!

@seokho-son

@seokho-son

@seokho son (CNCF / K8s Slack)

Senior Researcher & Special Fellow, ETRI

Ambassador, CLOUD NATIVE COMPUTING FOUNDATION

Maintainer, Cloud-Barista CB-Tumblebug

Maintainer, M-CMP Platform

Maintainer, CNCF Cloud Native Glossary

Lead, Kubernetes SIG-Docs Subproject

Lead, Kubernetes SIG-Docs Korean l10n Team

멀티 클라우드에 진심인 사람들의 이야기

멀티/분산 클라우드, 차세대 클라우드를 향한 도전과 기회

Cloud-Barista Community the 9th Conference

감사합니다.

shsonkorea@etri.re.kr

손 석 호